

TECNOLÓGICO DE MONTERREY

CAMPUS GUADALAJARA

Evidencia 4. Artículo de investigación - Deep learning

Por

Paola Enríquez Reyes

A01741055

Luis Jesús Castillo Goyenechea

A01275697

Erik Ernesto Ocegueda Sambrano

A01639729

Juan Pablo Bernal Lafarga

A01742342

Análisis de métodos de razonamiento e incertidumbre

Profesor Javier Edgardo Garrido Guillén

(Grupo 101)

08 de Septiembre de 2023

Abstract

Esta investigación se centra en el Deep Learning como una parte integral del campo de Machine Learning y su impacto en la inteligencia artificial. Las redes neuronales, inspiradas en el cerebro humano, permiten el aprendizaje a partir de grandes conjuntos de datos a través de capas profundas. Se aclara que el Deep Learning es un subconjunto del Machine Learning, con un poder computacional avanzado y la capacidad de aprender patrones por sí mismo.

En este se describe el proceso de entrenamiento de Redes Neuronales Convolucionales (CNN) para la clasificación de imágenes de gatos y perros. Se destaca la selección del mejor modelo basado en métricas como la precisión. Además, se explora la aplicación del Deep Learning en diversas industrias, incluyendo el procesamiento de lenguaje natural, la medicina, las finanzas, la conducción autónoma, el entretenimiento, la agricultura y la energía.

Concluyendo con una discusión que incluye gráficos comparativos de entrenamiento y validación, así como la clasificación exitosa de la imagen de Maya. El modelo seleccionado muestra una alta confianza en su predicción. Este estudio destaca el impacto significativo del Deep Learning en diversas áreas.

Introducción

Deep learning forma parte importante del área de machine learning, lo cuál nos lleva a tocar el tema de inteligencia artificial. En este las redes neuronales son algoritmos inspirados en el funcionamiento del cerebro humano, con la finalidad de aprender de grandes cantidades de datos.

Los algoritmos de deep learning realizan tienen un funcionamiento repetitivo que ayuda a mejorar de manera gradual el resultado a través de “deep layers” lo que permite el aprendizaje progresivo, en otras palabras, vamos entrenando el algoritmo. Deep learning ha tenido un gran impacto en los últimos años y esto ha detonado un desarrollo mayor respecto a la inteligencia artificial y todas sus ramas. El “deep learning” o aprendizaje profundo se puede utilizar para el análisis avanzado de imágenes, investigaciones, en el área de salud la predicción de problemas como síntomas de enfermedades.

Suele haber una leve confusión cuando se entra a este tema ya que se ve como una contraparte más que una parte de, se ve el deep learning como una tecnología que compite en contra de machine learning. Pero realmente, el deep learning es un subconjunto del machine learning; con un poder computacional acelerado y grandes conjuntos de datos. Los algoritmos de deep learning pueden llevar a cabo el auto-aprendizaje de patrones ocultos dentro de los datos para hacer predicciones y así mejorar por cuenta propia. En lugar de organizar datos para que se ejecuten a través de ecuaciones predefinidas, el deep learning configura parámetros básicos acerca de los datos y entrena a la computadora para que aprenda por cuenta propia reconociendo patrones mediante el uso de muchas capas de procesamiento.

Métodos

Para llevar a cabo el entrenamiento de nuestras Redes Neuronales Convolucionales (CNN), se realizaron las siguientes etapas para el desarrollo del algoritmo y el análisis de la situación problema.

Preparación de los Datos

Se descargaron aproximadamente 25,000 imágenes del conjunto de datos que se nos otorgó por el profesor, utilizando el siguiente código en un entorno local de Python:

```
bash
```

```
!curl -O
```

```
https://download.microsoft.com/download/3/E/1/3E1C3F21-ECDB-4869-8368-6DEBA77B919F/kagglecatsanddogs\_5340.zip
```

```
!unzip -q kagglecatsanddogs_5340.zip
```

Después de la descarga, pudimos explorar el directorio para verificar la integridad de los datos y comprender su estructura, donde también notamos algunos detalles como imágenes “corruptas”.

Reducción del Conjunto de Datos

Se trabajó con una muestra reducida. Se seleccionaron aleatoriamente 5,000 imágenes de gatos y perros para formar nuestro conjunto de datos de entrenamiento y prueba. Esta muestra se eligió de manera equitativa para asegurar una representación adecuada de ambas clases.

Entrenamiento de Diferentes CNN

Se procedió a entrenar varias Redes Neuronales Convolucionales (CNN) utilizando TensorFlow en un entorno local de Python. Se experimentaron con diferentes arquitecturas de CNN, ajustando hiperparámetros como el número de capas, el tamaño del kernel, la tasa de aprendizaje y la cantidad de neuronas en las capas ocultas. El objetivo principal fue lograr la mayor precisión posible en la clasificación de imágenes de gatos y perros.

Mejor Modelo

Cada modelo entrenado se evaluó utilizando el conjunto de prueba, calculando métricas como la precisión (accuracy), la cual fue de las principales mediciones que nos guió para la toma del mejor modelo; además de la pérdida y la matriz de confusión. Se seleccionó el modelo que alcanzó la mayor precisión en la clasificación de imágenes de gatos y perros como la mejor CNN para nuestro propósito.

Clasificación de Maya

Finalmente, se utilizó la mejor CNN entrenada para clasificar una imagen de Maya. Se aplicaron las técnicas de preprocesamiento necesarias a la imagen de entrada y se obtuvo una predicción sobre si la imagen contiene un gato o un perro.

Esto nos permitió entrenar y evaluar modelos de redes neuronales convolucionales utilizando una muestra representativa de imágenes de gatos y perros, con el objetivo de lograr una alta precisión en la clasificación de nuevas imágenes, como la de Maya.

Aplicación

El deep learning, es una disciplina prominente en el ámbito de la inteligencia artificial en las últimas décadas y es ampliamente destacable su influencia en varias industrias y campos de estudio.

Procesamiento de Lenguaje Natural (NLP): El deep learning ha revolucionado el conocido procesamiento de lenguaje natural. Estas capacidades son esenciales en la comunicación global, chatbots, asistentes virtuales y análisis de opiniones en redes sociales, lo que facilita una comprensión más profunda de la interacción humana en línea.

Área médica: En el ámbito de la salud, el deep learning se destaca en el diagnóstico médico, donde las redes neuronales profundas analizan imágenes médicas, como radiografías y resonancias magnéticas, para identificar patologías.

Finanzas: En el sector financiero, el deep learning ha sido fundamental en la predicción de precios y riesgos, lo que ayuda a los inversores y las instituciones financieras a tomar decisiones más informadas. También desempeña un papel crucial en la detección de fraudes, lo que garantiza la seguridad de las transacciones.


Conducción Autónoma: La conducción autónoma representa un campo donde el deep learning es esencial para la percepción y toma de decisiones de vehículos autónomos, lo que promete transformar la industria del transporte y mejorar la seguridad vial.

Juegos y Entretenimiento: En la industria del entretenimiento, el deep learning se aplica en el desarrollo de personajes no jugadores (NPC) más inteligentes y en la recomendación de contenido personalizado a los usuarios, mejorando así la experiencia del usuario en videojuegos y plataformas de streaming.

Agricultura y Energía: En la agricultura, el deep learning se utiliza en la optimización de cultivos y la detección de plagas, mientras que en la energía, ayuda a predecir la demanda de energía y a optimizar la producción, contribuyendo a un uso más eficiente de los recursos.

Discusión

Gráficas



En las tablas obtenidas podemos observar la comparación en el comportamiento del training y validation en cuanto accuracy y loss dentro del código utilizado que se va entrenando para

que este pueda categorizar correctamente las imágenes de perros y gatos. Con esto se fue evaluando los modelos para así poder encontrar la mejor opción para aplicar con la imagen objetivo de la situación problema y simplemente el gráfico nos ayuda a la lectura y comprensión del mismo; en este caso mientras mayor sea la la validación (accuracy) mejor es el modelo y por otro lado, pero no menos importante, mientras menor sea la pérdida (loss) mejor es el modelo.


Clasificación



Dentro del mejor modelo obtenido se nos da la clasificación obtenida con las imágenes descargadas. Para esto se tuvo que aplicar epoch, este se refiere al paso completo de datos de entrenamiento a través del algoritmo, determinando el proceso de entrenamiento del modelo

de aprendizaje automático. También se puede aplicar el algoritmo optimizador adam, el cual consta de optimización y se puede utilizar en lugar del clásico procedimiento de descenso de gradiente estocástico para actualizar los pesos de la red de forma iterativa en función de los datos de entrenamiento. En esta imagen de clasificación podemos comprobar el funcionamiento del modelo, ya que se ha obtenido una clasificación exitosa con el modelo con mejor accuracy y menor loss; es decir, el mejor modelo.

Imagen de Maya



Con una confianza del 90.64%, la imagen pertenece a la clase Dog.

Ya con nuestro modelo seleccionado y con la confianza de que este es el mejor modelo a aplicar. Finalizamos con la imagen de Maya, esta debe de ser clasificada a alguna de las clases (perro o gato); nuestro modelo clasifica la imagen en la clase Dog, lo cual es correcto y nos da una confianza del 90.64%, que si bien no es una confianza extraordinaria o perfecta realmente es una confianza bastante buena.

Referencias

-Deep learning - ¿Qué es deep learning? (s. f.).

<https://www.ibm.com/mx-es/cloud/deep-learning>

-¿Qué es deep learning? (s. f.). SAS.

https://www.sas.com/es_mx/insights/analytics/deep-learning.html

-Sarker, I. H. (2021). Deep Learning: a comprehensive overview on techniques, taxonomy, applications and research directions. *SN computer science*, 2(6).

<https://doi.org/10.1007/s42979-021-00815-1>

-Baraniuk, R. G., Donoho, D. L., & Gavish, M. (2020). The science of deep learning.

Proceedings of the National Academy of Sciences of the United States of America, 117(48), 30029-30032. <https://doi.org/10.1073/pnas.2020596117>

-Przybyla, M. (2021, 12 noviembre). ¿Cuándo es mejor evitar el uso de deep learning?

DataSource.ai.

<https://www.datasource.ai/es/data-science-articles/cuando-es-mejor-evitar-el-uso-de-deep-learning>